

Zadania ASU

mgr inż. Jerzy Sobczyk

dr inż. Adam Krzemienowski

25 luty 2022

Projekt Porządkowanie plików

Celem projektu jest zapoznanie się z problemami występującymi przy przeszukiwaniu drzewa katalogów i porównywaniu plików. Jest to zadanie wspólne dla wszystkich uczestników kursu. Do rozwiązania należy użyć jednego z języków programowania: Perl, Python, Bash. Można korzystać wyłącznie z bibliotek zainstalowanych na komputerach laboratoryjnych. Sprawdzenie będzie się odbywało na tych właśnie komputerach.

Założmy, że mamy duży zbiór dokumentów, nagrań, filmów i fotografii (kilkaset plików) w katalogu **X** i jego podkatalogach. Co gorsza mamy również jedną lub więcej kopii w katalogach **Y1**, **Y2**, ... w których te same pliki są w innych miejscach drzewa lub pod innymi nazwami. Mogą się też zdarzać braki niektórych plików zarówno w katalogu **X** jak i katalogach **Y1**, **Y2**, ... Celem jest uporządkowanie zbioru tak aby:

- w katalogu **X** znalazły się wszystkie pliki,
- zlikwidować duplikaty czyli spośród plików o identycznej zawartości zasugerować pozostawienie tylko najstarszego (nowsze daty są zapewne datami utworzenia kopii),
- zaproponować skasowanie plików pustych i tymczasowych,
- w przypadku plików o tej samej nazwie zasugerować pozostawienie nowszego,
- zasugerować ujednolicenie atrybutów np. `rw-r--r--`,
- zasugerować przemianowanie plików, których nazwy zawierają znaki mogące komplikować operowanie nimi (np. `:', ''', '.', ';', '*', '?', '$', '#', '"', '|', '\', ...`) zastępując te znaki zdefiniowanym substytutem np. `_`.

Skrypt powinien więc potrafić wyszukiwać:

- pliki o identycznej zawartości (choć niekoniecznie identycznej nazwie i niekonieczne w analogicznej pozycji w drzewie),

- pliki puste,
- nowsze wersje plików o tej samej nazwie (choć niekoniecznie znajdujące się w analogicznym katalogu),
- pliki tymczasowe (*~, *.tmp, ew. inne rozszerzenia zdefiniowane przez użytkownika),
- pliki o nietypowych atrybutach np. rwxrwxrwx,
- pliki o nazwach zawierających kłopotliwe znaki,

Dla każdego znalezionej pliku skrypt powinien zaproponować odpowiednią akcję:

- przeniesienie (lub przekopiowanie) do odpowiedniego miejsca w katalogu **X**,
- skasowanie duplikatu, pliku pustego lub tymczasowego,
- zastąpienie starszej wersji nowszą,
- zastąpienie wersji nowszej starszą (w przypadku plików z identyczną zawartością),
- zmianę atrybutów,
- zmianę nazwy,
- pozostawienie bez zmian,

Musi być też możliwość wybrania akcji wspólnej dla wszystkich plików np. zawsze kasuj, zawsze kopiuj, zawsze zostawiaj, zawsze poprawiaj atrybuty, ..

Skrypt nie musi wszystkich tych funkcji wykonywać jednocześnie. Jego użycie może wymagać kilkukrotnego uruchamiania, np. w jednym przebiegu wyszukujemy i kasujemy pliki puste, w innym duplikaty, w jeszcze innym odnajdujemy nowsze wersje, itd. Program musi być odporny na wszelkie znaki w nazwach plików i katalogów.

Parametry takie jak:

- sugerowana wartość atrybutów pliku np. rw-r-r-
- zbiór znaków kłopotliwych,
- znak będący substytutem znaków kłopotliwych,
- rozszerzenia plików uznawanych za tymczasowe,

należy wczytywać z pliku konfiguracyjnego np.: `$HOME/.clean_files`

Listę katalogów do sprawdzenia należy pobierać z linii komendy.